Introduction

The aim of this essay is to introduce us to pandas library and to demostrate how we can apply functions of pandas library to extract insights of the dataset.

The description of the dataset can be found in the following link

(https://https://www.kaggle.com/code/abdurrehmankhalid/airplane-dataset-analysis)

First thing first, we have to upload our dataframe. I upload the dataframe from my google drive. You can upload the dataframe also from your pc

```
import pandas as pd  # import the main library
from google.colab import drive  # import the dataframe
drive.mount("/content/gdrive")

Drive already mounted at /content/gdrive; to attempt to forcibly remount, call drive

data=pd.read_excel("/content/gdrive/MyDrive/Pandas Delaited Flights/DelayedFlights.xlsx")
```

▼ First question:

Find and display the exact number of rows in each column that contains nas.

Πρώτη ερώτηση

data.isnull().sum()

να βρείτε (αν υπάρχουν) και να εμφανίσετε το πλήθος των κενών γραμμών σε κάθε στήλη του dataset

```
Unnamed: 0 0
Year 0
Month 0
DayofMonth 0
DayOfWeek 0
DepTime 0
```

CRSDepTime	0
ArrTime	3896
CRSArrTime	0
UniqueCarrier	0
FlightNum	0
TailNum	4
ActualElapsedTime	3896
CRSElapsedTime	157
AirTime	3896
ArrDelay	3896
DepDelay	0
Origin	0
Dest	0
Distance	0
TaxiIn	3896
TaxiOut	0
Cancelled	0
CancellationCode	0
Diverted	0
CarrierDelay	362841
WeatherDelay	362841
NASDelay	362841
SecurityDelay	362841
LateAircraftDelay	362841
new	3896
dtype: int64	

data.info()

<class 'pandas.core.frame.DataFrame'>
RangeIndex: 1048575 entries, 0 to 1048574

Data columns (total 31 columns):

#	Column	Non-Null Count	Dtype
0	Unnamed: 0	1048575 non-null	
1	Year	1048575 non-null	int64
2	Month	1048575 non-null	int64
3	DayofMonth	1048575 non-null	int64
4	DayOfWeek	1048575 non-null	int64
5	DepTime	1048575 non-null	float64
6	CRSDepTime	1048575 non-null	int64
7	ArrTime	1044679 non-null	float64
8	CRSArrTime	1048575 non-null	int64
9	UniqueCarrier	1048575 non-null	object
10	FlightNum	1048575 non-null	int64
11	TailNum	1048571 non-null	object
12	ActualElapsedTime	1044679 non-null	float64
13	CRSElapsedTime	1048418 non-null	float64
14	AirTime	1044679 non-null	float64
15	ArrDelay	1044679 non-null	float64
16	DepDelay	1048575 non-null	float64
17	Origin	1048575 non-null	object
18	Dest	1048575 non-null	object
19	Distance	1048575 non-null	int64
20	TaxiIn	1044679 non-null	float64
21	TaxiOut	1048575 non-null	float64
22	Cancelled	1048575 non-null	int64
23	CancellationCode	1048575 non-null	object
24	Diverted	1048575 non-null	int64

```
25 CarrierDelay
                    685734 non-null
                                      float64
26 WeatherDelay
                    685734 non-null
                                      float64
27 NASDelay
                      685734 non-null
                                      float64
28 SecurityDelay 685734 non-null float64
29 LateAircraftDelay 685734 non-null
                                      float64
                      1044679 non-null float64
30 new
dtypes: float64(15), int64(11), object(5)
memory usage: 248.0+ MB
```

Second Question

Calculate and display in which day and in which month were noted the most delays

Ερώτηση 2:

να υπολογίσετε και να εμφανίσετε ποια ημέρα σε ποιον μήνα σημειώθηκαν οι περισσότερες καθυστερήσεις πτήσεων

4 155264 5 153072 dtype: int64

```
d_2=data[["Month","ArrDelay","DayofMonth"]].groupby(["Month","DayofMonth"]).max().reset_ir
d_2.sort_values(by='ArrDelay', ascending=False)
```

	Month	DayofMonth	ArrDelay	1
33	2	3	2461.0	

d_2=data[["Month","ArrDelay","DayofMonth"]].groupby(["Month","DayofMonth"]).max().reset_ir
d_2

	Month	DayofMonth	ArrDelay
33	2	3	2461.0
100	4	10	2453.0
126	5	6	1951.0
171	6	20	1707.0
117	4	27	1542.0
128	5	8	478.0
38	2	8	474.0
140	5	20	456.0
84	3	25	448.0

The answer is in second month on 3 day 2461 flights were delayed

→ Third Question

Calculate and display the daily mean of delays for each summer month $E\rho\dot{\omega}\tau\eta\sigma\eta~3;$

να υπολογίσετε και να εμφανίσετε τον ημερήσιο μέσο όρο καθυστερήσεων για καθέναν από τους θερινούς μήνες του 2008

```
#print(data["Month"],type)
#"ArrDelay"

d_3=data.loc[(data["Year"]==2008) & (data["Month"]==6),["Month","ArrDelay","DayofMonth"]].
d_3
```

	Month	ArrDelay
DayofMonth		
8	6.0	63.704009
4	6.0	59.005208
22	6.0	57.745626
29	6.0	55.294398
26	6.0	54.224555
16	6.0	53.228567
6	6.0	50.792295
3	6.0	50.416815
10	6.0	49.778672
13	6.0	48.819565
9	6.0	47.340510
15	6.0	47.300329
5	6.0	46.668798
23	6.0	46.451584
19	6.0	46.348048
27	6.0	45.115582
14	6.0	44.656481
7	6.0	43.175140
28	6.0	43.050468
18	6.0	40.803148
25	6.0	39.595063
17	6.0	39.385833
21	6.0	38.924731
11	6.0	<u> </u>

→ Fourth 4:

Calculate and diplay the name of the air transport company which had the biggest number of cancheled flights type B

Ερώτηση 4

να υπολογίσετε και να εμφανίσετε το όνομα της αεροπορικής εταιρίας που είχε το μεγαλύτερο πλήθος κωδικών ακύρωσης τύπου Β

```
print(data["CancellationCode"],type)
#data["CancellationCode"].count_values()
data["CancellationCode"].nunique()
#data["CancellationCode"]=="B"
     0
                N
     1
                Ν
     3
                Ν
     1048570
     1048571
     1048572
                N
     1048573
                N
     1048574
     Name: CancellationCode, Length: 1048575, dtype: object <class 'type'>
print(data["UniqueCarrier"],type)
data["UniqueCarrier"].nunique()
                WN
     0
                WN
     2
                WN
                WN
     3
                WN
     1048570
                AA
     1048571
                AA
     1048572
                AΑ
     1048573
                AA
     1048574
     Name: UniqueCarrier, Length: 1048575, dtype: object <class 'type'>
     20
```

There is no cancelation code type B

→ Fifth 5

Find the number of flights with biggest number of delays

Ερώτηση 5

να βρείτε τους κωδικούς των πτήσεων με τον μεγαλύτερο αριθμό καθυστερήσεων

d_5=data.loc[:,["FlightNum","ArrDelay"]].groupby("FlightNum").sum().reset_index().sort_val
d_5.head(10)

	FlightNum	ArrDelay
376	378	39044.0
48	50	37402.0
34	36	36718.0
319	321	36429.0
508	510	35726.0
73	75	34889.0
332	334	32868.0
682	685	32060.0

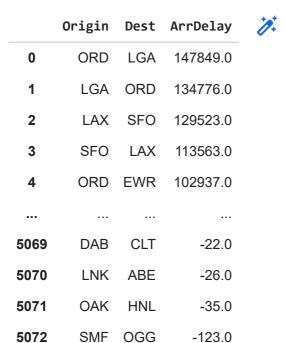
- Sixth 6:

Find and display the name of the biggest destination with the most delays

Ερώτηση 6

να βρείτε και να υπολογίσετε το όνομα του μεγαλύτερου σε απόσταση προορισμού με τις περισσότερες καθυστερήσεις

d_6=data.loc[:,["Origin","Dest","Distance","ArrDelay"]].groupby(["Origin","Dest"]).agg({"/
d_6



→ Seventh 7:

Find and display the destinations that had the biggest delay

να βρείτε και να εμφανίσετε τους προορισμούς που είχαν την μεγαλύτερη καθυστέρηση (πτήσεις που εκτελέστηκαν)

 $d_7 = data.loc[data["CancellationCode"] == "N", ["Dest", "ActualElapsedTime"]].groupby("Dest").actualElapsedTime"]].actualElapsedTime"]].groupby("Dest").actualElapsedTime"]].groupby("Dest").actualElapsedTime"]].groupby("Dest").actualElapsedTime"]].groupby("Dest").actualElapsedTime"]].groupby("Dest").actualElapsedTime"]].groupby("Dest").actualElapsedTime"]].groupby("Dest").actualElapsedTime"]].groupby("Dest").actualElapsedTime"]].groupby("Dest").actualElapsedTime"]].groupby("Dest").actualElapsedTime"]].groupby("Dest").actualElapsedTime"]].groupby("Dest").actualElapsedTime"]].groupby("Dest").actualElapsedTime"]].groupby("Dest").actualElapsedTime"]]].groupby("Dest").actualElapsedTime"]].groupby("Dest").actualElapsedTime"]].groupby("Dest").actualElapsedTime"]].groupby("Dest").actualElapsedTime"]].groupby("Dest").actualElapsedTime"]].groupby("Dest").actualElapsedTime"]].groupby("Dest").actualElapsedTime"]].groupby("Dest").actualElapsedTime"]].groupby("Dest").actualElapsedTime"]].groupby("Dest").actualElapsedTime"]].groupby("Dest").actualElapsedTime"][].groupby("Dest").actualElapsedTime"][].groupby("Dest").actualElapsedTime"][].groupby("Dest")$

ActualElapsedTime



Dest

- Eighth

Find and display the name of the airport company that had the most delays due to late arrival of aircrafts

Ερώτηση 8:

να βρείτε και να εμφανίσετε το όνομα της αεροπορικής εταιρείας που είχε τις μεγαλύτερες καθυστερήσεις που οφείλονται σε καθυστερημένη άφιξη αεροσκαφών

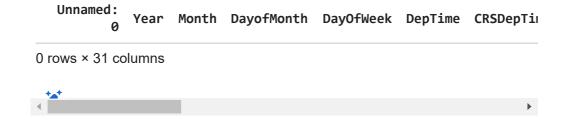
d_8=data.loc[:,["UniqueCarrier","LateAircraftDelay"]].groupby("UniqueCarrier").agg({"Late/d_8

Nineth Question

Calculate how many type A flight cancellations occured on 13th day of each month

Ερώτηση 9:

να υπολογίσετε πόσες ακυρώσεις πτήσεων τύπου Α σημειώθηκαν την 13η ημέρα κάθε μήνα



None

Tenth question

calculate and display the average delay of flights operated from 10 to 19 April 2008

Ερώτηση 10:

υπολογίσετε και να εμφανίσετε την μέση καθυστέρηση πτήσεων που εκτελέστηκαν από την 10η μέχρι την 19 Απριλίου 2008

```
Unnamed:
0 Year Month DayofMonth DayOfWeek DepTime CRSDepTin
0 rows × 31 columns
```

▼ Eleventh question

#"np.nanmean"

calculate and display the month with the longest delay due to security checks during the hours 06.00-14.00

να υπολογίσετε και να εμφανίσετε τον μήνα που σημειώθηκε η μεγαλύτερη καθυστέρηση που οφειλόταν σε έλεγχους ασφαλείας κατά τις ώρες 06.00-14.00

```
data["SecurityDelay"].sum()
#data["DepTime"]
63968.0

import numpy as np
d_11=data.loc[(data["DepTime"]>=600) & (data["DepTime"]<=1400),["Month","SecurityDelay","[d_11</pre>
```

	Month	SecurityDelay	1
0	3	7486.0	
1	1	5555.0	
2	2	4719.0	
3	5	4287.0	
4	6	3217.0	

```
import numpy as np
d_11=data.loc[(data["DepTime"]>=600) & (data["DepTime"]<=1400),["Month","SecurityDelay","[
.groupby("Month").agg({"SecurityDelay":"sum"}).sort_values(by="SecurityDelay",ascending=Fad_11
#"np.nanmean"</pre>
```

	Month	SecurityDelay	1
0	3	7486.0	
1	1	5555.0	
2	2	4719.0	
3	5	4287.0	
4	6	3217.0	

▼ Twelveth question.

Calculate and print which code of flight had the first and the tenth day of 6 month of 2008 the

Ερώτηση 12:

να υπολογίσετε και να εμφανίσετε ποιος κωδικός πτήσης(αριθμός πτήσης) είχε την πρώτη και δέκατη μέρα έκτου μήνα του 2008 την μεγαλύτερη προ του αναμενόμενου χρόνου άφιξη στον προορισμό της

```
# Πρώτος τρόπος #First way  d_12=data.loc[(data["DayofMonth"]==1) \ | \ (data["DayofMonth"]==10) \ \& \ (data["Month"]==6) \ \& \ (cd_12["new"]=d_12["ArrTime"]-d_12["CRSArrTime"] \\ d_12.groupby("FlightNum").agg({"new":"sum"}) \\ d_12.
```

	DayofMonth	Month	ArrTime	CRSArrTime	FlightNum	ne
30743	1	1	1303.0	1245	2679	58.
30751	1	1	854.0	821	1	33.
30754	1	1	6.0	2342	10	-2336.
30782	1	1	1219.0	1146	103	73.
30792	1	1	1240.0	1223	105	17.
1048449	1	6	1430.0	1350	1481	80.
1048517	1	6	2356.0	2330	1488	26.
1048547	1	6	1720.0	1640	1494	80.
4						•

```
d_12=data.loc[(data["DayofMonth"]==1) | (data["DayofMonth"]==10) & (data["Month"]==6) & (c
new=d_12.groupby("FlightNum").apply(lambda d_12: (d_12["ArrTime"] - d_12["CRSArrTime"])).r
#sort_values(by="0",ascending=False).reset_index()
new
#d_12
```



```
FlightNum level_1
  0
                1
                     30751
                             33.0
  1
                     66587
                             19.0
  2
                1
                    168251
                             40.0
  3
                1
                    168334
                            100.0
                    175614
                              -3.0
  4
38827
            7826
                    220845
                             52.0
38828
            7826
                    414762
                             66.0
38829
            7828
                     33252
                            117.0
38830
            7828
                    220857
                             92.0
```

```
# Δεύτερος τρόπος def subtract(x):    # x is a DataFrame of group values    x["new"]=d_12["ArrTime"]-d_12["CRSArrTime"]    return x
```

modified the question and we take the first 10 days

```
d_12=data.loc[(data["DayofMonth"]==1|2|3|4|5|6|7|8|9|10) & (data["Month"]==6) & (data["Arr
```

```
new=d_12.groupby("FlightNum").apply(subtract).reset_index()
ok=new.sort_values(by="new",ascending=False)
#sort_values(by="0",ascending=False).reset_index()
ok
```

	index	DayofMonth	Month	ArrTime	CRSArrTime	FlightNum
617	1031732	15	6	1227.0	1228	1785

den trexei gt to Arrtime exei nas d_12

	FlightNum	num
0	9	-1.0
1	1006	-1.0
2	1785	-1.0
3	1688	-1.0
4	1679	-1.0
629	206	-2357.0
630	6642	-2358.0
631	24	-2367.0
632	60	-4256.0

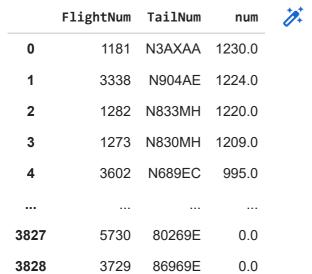
▼ Thirteenth question

find and display flights that were diverted but completed and the total time taken

Ερώτηση 13:

να βρείτε και να εμφανίσετε τις πτήσεις που εκτράπηκαν από την πορεία τους αλλά ολοκληρώθηκαν καθώς και τον συνολικό χρόνο που απαιτήθηκε

```
d_14=data.loc[(data["Diverted"]==1) & (data["CancellationCode"]=="N"),["Diverted","Cancell
.assign(num=lambda x: x["CRSElapsedTime"]+x["DepDelay"]).\
groupby(["FlightNum","TailNum"]).agg({"num":"sum"}).sort_values(by="num",ascending=False).
d_14
```



91629E

2780 N710BR

0.0

-2.0

9741

→ Fourteenth

3829

3830

which month had the largest standard deviation in delays ("most unpredictable month"). The difference between the planned and the actual flight execution time should be considered as a deviation

Ερώτηση 14:

ποιος μήνας είχε την μεγαλύτερη τυπική απόκλιση σε καθυστερήσεις ("πιο απρόβλεπτος μήνας"). Ως απόκλιση να θεωρηθεί η διαφορά ανάμεσα στον προγραμματισμένο και τον πραγματικό χρόνο εκτέλεσης της πτήσης

```
import statistics
from statistics import stdev
data["new"]=np.subtract(data["CRSElapsedTime"],data["ActualElapsedTime"])
data["new"].describe()
data["new"].std()

16.9215187679791

d_15=data.loc[(data["new"]>0),["Month","new"]].groupby("Month").agg({"new":["std","mean",s" #sort_values(by="std",ascending=False).reset_index()
d_15
#groupby("Month")
```

Month new

		std	mean	sum	min	max
0	1	7.620670	10.352972	1115336.0	1.0	90.0
1	2	7.428301	10.028041	1087531.0	1.0	101.0
2	3	7.529717	10.081771	1213946.0	1.0	151.0
3	4	7.433828	10.004471	924163.0	1.0	76.0

5 7.457911 10.026340 937162.0 1.0 181.0

Colab paid products - Cancel contracts here

✓ 0s completed at 3:11 PM